实证公司金融中的内生性

识别、来源与处理策略

Roberts & Whited (2013)

今天讲些什么

这节课会围绕五个板块展开：

- 内生性到底是怎么一回事，以及它从哪儿来
- 潜在结果框架——为什么简单比较往往不能说明问题
- 四种主流的识别策略：IV、双重差分、断点回归和匹配
- 面板数据方法，以及测量误差的几种补救思路
- 最后谈谈我个人对这类研究的一点看法

内生性的定义

考虑最基本的线性回归：

$$y = \beta_0 + \beta_1 x + u$$

OLS 要得到一致估计，一个前提是：

$$cov(x, u) = 0$$

如果这个条件被打破了，我们就说模型存在**内生性**。

“ 这里要特别提醒一点：没有任何统计检验能直接告诉你"内生性已经被解决了"。识别策略到底靠不靠谱，归根结底要靠经济学论证来说服读者。 ”

内生性从哪儿来

在公司金融里，内生性通常来自四个方面：

来源	怎么回事	常见的例子
遗漏变量	有些重要因素观测不到，却又和解释变量相关	CEO 能力、企业的真实投资机会
联立性	x 和 y 其实是市场里一起被决定的	杠杆率与投资决策互为因果
测量误差	代理变量和真实概念之间有系统性偏差	Tobin's q、公司治理指数
样本选择	你看到的样本不是随机抽来的	上市公司、获批贷款的企业

公司金融的内生性为何格外棘手

这个领域几乎每一个变量都是管理层优化决策的结果，而优化过程依赖大量私有信息——这些信息进了误差项，天然就和解释变量相关。

再加上变量之间反馈环路很多：杠杆影响投资，投资又反过来影响融资决策。更麻烦的是，理论里常说的"投资机会"、"代理成本"、"治理质量"这类概念，根本找不到完美的代理变量。

后果可能是灾难性的：系数符号被颠倒、政策建议被误导，甚至把资本错误配置到不该去的地方。

遗漏变量偏差

假设真实模型是：

$$y = \beta x + \gamma w + u$$

但 w 观测不到。如果 w 和 x 相关，复合误差项 $v = \gamma w + u$ 就不再和 x 独立，OLS 估计当然是有偏的。

举两个公司金融里经典的例子：

- 现金流和投资的关系。Fazzari 等人的著名研究发现投资对现金流敏感，但现金流不只是融资约束的反映，它也代理了未来的投资机会。如果投资机会没控制好，现金流的系数就会被高估。
- 盈利能力与杠杆率。Rajan & Zingales 发现盈利高的企业杠杆低，但这可能只是因为经营风险同时影响了盈利和杠杆选择，而不是优序融资理论的直接证据。

联立性偏差

当 y 和 x 由市场均衡共同决定时，单向因果的假定就失效了。

- 反收购条款与公司价值。到底是反收购条款毁掉了公司价值，还是本来价值就低的公司更愿意采纳反收购条款来保护管理层？
- 股利政策。高股利企业通常估值不错，但这很可能只是因为成熟、低成长的自然结果，而不是股利本身创造了价值。
- 多元化折价。Villalonga 指出，多元化企业市值更低，但真相也许是主营业务陷入困境的企业才被迫多元化。

“ 联立性偏误的符号往往很难事先判断，因为它取决于多重弹性与冲击方差的相对大小。 ”

测量误差

如果因变量的测量误差和解释变量不相关，OLS 仍是一致的，只是标准误会变大；但如果相关，偏误就来了。

更常见的是自变量存在经典测量误差。此时会出现**衰减偏误**：

$$plim\ \hat{\beta} = \beta \frac{\sigma_r^2}{\sigma_r^2 + \sigma_w^2}$$

系数绝对值被压向零。不过要注意，一旦多个变量同时被误测，偏误方向可能变得非常复杂——比如在投资回归里，Tobin's q 的测量误差反而可能让现金流的系数被严重高估。

样本选择偏误

研究者拿到的样本往往不是总体的随机子集。如果进入样本的概率和某些不可观测因素有关，那基于这个样本的推断就很难推广。

公司金融里到处都是这种陷阱：

- Compustat 里的上市公司本身就不是随机企业
- 银行数据库里只有获批贷款的借款人，被拒贷的企业你看不到
- 分析师覆盖的样本偏向大市值、高流动性公司
- 并购研究里只保留了最终完成的交易，失败案例被系统性排除

Heckman 两阶段模型

Heckman (1979) 的处理思路是这样的：

先跑一个 Probit 或 Logit，估计个体进入样本的概率，算出逆米尔斯比率 λ；再把 λ 放到第二阶段的结果方程里。如果 λ 显著，就说明样本选择偏误确实存在。

最困难的地方在于找**排他性变量**——它得影响是否进入样本，但又不能直接影响结果。在公司金融里，这通常要依赖对制度背景的深入理解，比如某家银行内部的信贷政策偏好，或者某次外部信贷紧缩冲击。

潜在结果框架

Rubin 的因果模型里，每个个体有两个潜在结果：$y(1)$ 和 $y(0)$。我们实际看到的是：

$$y = y(0) + d[y(1) - y(0)]$$

把处理组和未处理组的简单均值差异拆开，会得到：

$$E(y|d=1) - E(y|d=0) = \underbrace{ATT}_{\text{处理效应}} + \underbrace{\text{选择偏误}}_{\text{反事实差异}}$$

“只有在处理分配是随机的（或与潜在结果独立）时，第二项才为零，简单比较才能识别因果效应。”

工具变量法的基本思想

如果 x 是内生的，我们需要找一个工具变量 z，它得满足两个条件：

- **相关性**：z 和 x 显著相关。这个可以检验。
- **排他性约束**：z 只能通过 x 影响 y，不能走别的路。这个**没法直接检验**，只能靠经济学故事和制度细节来说服人。

2SLS 的直觉很简单：把 x 的波动分成"干净的"和"脏的"两部分，只用干净的那部分来识别参数。

IV 的检验、局限与常见误区

过度识别检验（Sargan / Hansen J）有个隐含前提：至少得有一个工具变量是真正外生的。它从来不能替代对排他性的经济学论证。

弱工具变量是另一个大坑。Stock-Yogo 的经验法则告诉我们，3 个 IV 时第一阶段 F 统计量最好大于 9.08，否则 2SLS 在小样本里可能比 OLS 还糟。

还有一个常见误区是拿**滞后变量当 IV**。公司金融数据持续性很强，如果当期 x 和误差项相关，滞后项往往也相关。没有明确的经济学论证，不建议这么干。唯一被严格认可的场景是基于理性预期的欧拉方程估计。

IV 还能告诉我们什么、不能告诉我们什么

IV 估计出来的是 **LATE**（局部平均处理效应），也就是那些因为工具变量才从"不接受处理"变成"接受处理"的群体（compliers）的平均效应。它不一定能推广到整个人群。

另外，如果你的模型里同时有好几个内生变量，但只给其中一部分找到了 IV，那其余系数的估计仍然不能保证一致。

最后，即使工具变量本身是随机的，如果处理效应在人群中异质，而且个体会根据预期收益自我选择，IV 也可能出问题。

几个经典的 IV 案例

研究	关心的问题	工具变量	为什么外生
Angrist & Krueger (1991)	教育回报	出生季度	义务教育入学截止日带来的外生差异
Card (1995)	移民对本地劳动力市场的影响	马里尔船运事件	1980 年古巴难民突然涌入迈阿密
Duflo (2001)	学校建设的回报	印尼各地区新建学校数量	1973–1978 年印尼大规模建校计划
Bennedsen et al. (2007)	家族 CEO 继任对企业绩效的影响	家族长子/长女的性别	纯粹的生物学随机事件

双重差分法

DD 的巧妙之处在于同时做两次差分：

$$y = \beta_0 + \beta_1(d \times p) + \beta_2 d + \beta_3 p + u$$

	处理后	处理前	差分
处理组	$\beta_0 + \beta_1 + \beta_2 + \beta_3$	$\beta_0 + \beta_2$	$\beta_1 + \beta_3$
控制组	$\beta_0 + \beta_3$	β_0	β_3
差分	$\beta_1 + \beta_2$	β_2	β_1

横截面差分去掉组间固定差异，时间差分去掉共同趋势，剩下的就是处理效应。

平行趋势假设与怎么验证它

DD 最核心的假设是：**如果没有政策冲击，处理组和控制组的趋势本来应该是一样的**。这个假设在数学上没法直接检验，但你可以做几件事来增强可信度：

- 画事件前趋势图，看两组在政策前是否平行
- 做安慰剂检验，把处理时间人为提前一年或两年，看看"虚假"的处理效应是否显著
- 找几个理论上不应该受政策影响的变量做替换检验
- 如果有多个处理组或控制组，可以进一步做三重差分（DDD）

断点回归设计

RDD 的想法很直接：既然处理分配完全取决于某个临界点，那就在临界值附近找因果效应。临界点两边的企业，只要差一点没跨过去，本质上应该非常相似。

Sharp RDD：一过临界点就一定被处理。比如 Chava & Roberts (2008) 研究的银行贷款契约财务比率阈值。

Fuzzy RDD：临界点只是提高了被处理的概率。比如 Keys et al. (2010) 发现的 FICO 评分在 620 附近贷款证券化概率的跳跃。

“ 这里的关键假设是局部连续性：潜在结果在临界点处是光滑的，没有跳跃。 ”

RDD 怎么做、怎么才算靠谱

估计上，你有两种选择：

- 参数化：在临界点两侧分别拟合多项式
- 非参数化：只用临界点附近一个带宽 h 内的样本做局部线性回归

稳健性检验包括：

- McCrary 密度检验：看企业会不会人为操纵分配变量来刚好跨过门槛
- 协变量平衡检验：用不受处理影响的变量做 RDD，看临界点处有没有不该有的跳跃
- 安慰剂检验：在假的临界点处跑一遍，看看是不是只有真临界点显著

匹配方法

匹配的基本想法是：给每个处理组个体找一个在可观测特征上"最像"的控制组个体，从而构造出反事实结果。

但这个方法高度依赖两个假设：

- **无混淆性**：控制了可观测变量 X 之后，潜在结果和处理分配独立。这个假设非常强，而且没法检验。
- **共同支撑**：对于每一个 X 的取值，处理组和控制组都得有人。否则你根本找不到可比的匹配对象。

因为无混淆性假设太强，匹配在公司金融里很少能独立解决根本的内生性问题，更适合作为**稳健性检验**，或者和 DD 结合起来用。

面板数据方法

面板数据模型可以写成：

$$y_{it} = \beta_0 + \beta_1 x_{it} + c_i + e_{it}$$

固定效应（FE） 假设 c_i 和 x_{it} 相关，通过去均值变换把 c_i 消掉。它能解决不随时间变化的遗漏变量问题，但也有代价：

- 会加剧测量误差问题
- 对时变遗漏变量无能为力
- 如果 y 本身已经是差分形式（比如投资、现金持有变化），c_i 可能早就被差分掉了，这时候再用 FE 只会损失效率

随机效应（RE） 假设 c_i 和 x_{it} 不相关，此时 OLS 仍一致，RE 只是通过 FGLS 提高效率。

测量误差的计量修正

Erickson & Whited (2000) 提出了一种高阶矩估计量：

$$\hat{\beta} = E(y^2x)/E(yx^2)$$

这个方法能识别的关键是真实变量 x^* 的三阶矩不为零，也就是分布要偏态。对公司金融里的 marginal q 来说，这个条件天然满足，因为 q 不可能为负。

另一个实用的诊断工具是**反向回归边界**。直接回归会低估真实系数，反向回归会高估，真实系数一定落在这两者之间。如果区间不包含零，至少可以确认 OLS 估计的符号是可信的。

用代理变量时的一点建议

第一，如果修正方法背后的假设本身就不太可信，不要为了用技术而用技术。

第二，在研究设计阶段，尽量选那些让拒绝原假设变得更难的代理变量。宁可犯第二类错误，也不要犯第一类错误。

第三，很多时候用代理变量做个粗分比较——比如只看分布最高和最低的两组——反而比精细的回归估计更稳健。

一点个人看法

“ 我不认为回归本身能够承担因果论证的大部分重担。技术修补并不能解决深层次的问题。
— David Freedman ”

这话虽然说得重，但值得我们时刻记住。没有哪种计量方法是万金油；在非实验数据里，内生性永远不可能被"证明"已经消除。我们能做的是通过扎实的经济学论证、详尽的制度背景分析和充分的稳健性检验，让读者愿意相信我们的故事。

另外，也不是每篇论文都必须以因果识别为唯一目标。描述性的、发现新规律的实证工作，同样是这个领域不可或缺的基础。

如果要做一项研究，建议怎么入手

首先，先想清楚识别问题：哪些变量可能是内生的？为什么？偏误的方向大概会怎样？

然后，再决定用哪类工具：是去外面找外生变异（IV、DD、RDD），还是依赖模型结构和数据特征（匹配、FE、测量误差修正）？

对于那些不可检验的假设——比如 IV 的排他性、DD 的平行趋势、匹配的无混淆性——要靠经济学逻辑和制度细节去论证，而不是靠某个检验的 p 值。

最后，尽可能多地报告不同规格、不同带宽、不同样本限制下的结果，让你的核心结论经得起敲打。

谢谢

有什么问题欢迎讨论。