关联规则挖掘作业任务

一、学习目标

完成本作业后，学生应能够：

1. 理解关联规则的基本概念（支持度、置信度、提升度）
2. 掌握 Apriori 算法的原理和实现
3. 掌握 FP-Growth 算法的原理和实现
4. 能够进行多维关联规则挖掘
5. 能够进行时序关联规则分析
6. 能够对挖掘结果进行业务解读和可视化展示

二、数据说明

3.1 数据来源

文件：`bank_transactions.csv`

3.2 数据规模

- 交易记录数：3000 条
- 客户数：500 人
- 时间跨度：2025 年 1 月 - 2025 年 12 月（12 个月）
- 产品种类：15 种银行金融产品

3.3 字段说明

字段名	说明	示例值
customer_id	客户 ID	C0001
age_group	年龄段	25-30, 31-35, 36-40, 41-45, 46-50
income_level	收入水平	低，中，高
occupation	职业类型	企业职员，公务员，个体户，自由职业，退休人员
risk_tolerance	风险偏好	保守型，稳健型，进取型
transaction_date	交易日期	2025-01-15

字段名	说明	示例值
transaction_month	交易月份	2025-01
products	购买产品列表（逗号分隔）	活期存款，信用卡，理财产品
product_categories	产品类别列表（逗号分隔）	存款类，信贷类，投资类
total_amount	交易总金额	85000

3.4 产品列表

产品类别	产品名称
存款类	活期存款、定期存款、大额存单
投资类	理财产品、基金、股票、国债、贵金属、外汇、信托
保障类	保险、年金
信贷类	信用卡、消费贷款、住房贷款

三、任务要求

任务一：数据探索与预处理（15 分）

要求：

1. 加载数据并进行基本统计描述
2. 分析各字段的分布情况（年龄段、收入水平、职业、风险偏好）
3. 统计各产品的购买频率
4. 分析交易金额的基本统计量（均值、中位数、最大值、最小值）
5. 将 products 字段转换为适合关联规则挖掘的格式（One-Hot 编码或事务列表）

提交内容：

- 数据探索的代码和结果
- 至少 3 个可视化图表（如产品购买频率柱状图、年龄段分布饼图等）

任务二：基础关联规则挖掘（25 分）

要求：

1. 使用 **Apriori 算法** 挖掘频繁项集
    - 设置最小支持度阈值（建议 0.05-0.1）
    - 设置最小置信度阈值（建议 0.3-0.5）
    - 找出所有频繁项集
2. 从频繁项集中生成关联规则
    - 计算每条规则的支持度、置信度、提升度
    - 筛选出强关联规则（提升度 > 1）
3. 使用 **FP-Growth 算法** 重复上述过程
    - 比较两种算法的运行时间
    - 比较两种算法挖掘出的规则差异

提交内容：

- Apriori 算法实现代码
- FP-Growth 算法实现代码
- 频繁项集列表（Top 20）
- 强关联规则列表（Top 10，按提升度排序）
- 两种算法的性能对比分析

任务三：多维关联规则挖掘（25 分）

要求：

1. **按年龄段分组挖掘**
    - 将数据按 age_group 分为 5 组
    - 对每组分别挖掘关联规则
    - 比较不同年龄段的购买模式差异
2. **按收入水平分组挖掘**
    - 将数据按 income_level 分为 3 组
    - 对每组分别挖掘关联规则
    - 分析收入对产品组合的影响
3. **按风险偏好分组挖掘**
    - 将数据按 risk_tolerance 分为 3 组
    - 对每组分别挖掘关联规则
    - 分析风险偏好与投资产品选择的关系
4. **交叉维度分析**

    - 选择两个维度进行交叉分析（如：收入×年龄段）
    - 发现特定人群的产品偏好模式

提交内容：

- 各维度分组挖掘的代码
- 各分组的强关联规则对比表
- 至少 2 个有业务洞察的发现（如："高收入 +31-40 岁人群偏好基金 + 理财产品组合"）
- 可视化展示不同群体的规则差异

任务四：时序关联规则分析（25 分）

要求：

1. **按时间序列分析产品购买模式**
    - 将数据按 transaction_month 分组
    - 分析各月产品购买频率的变化趋势
    - 识别季节性或周期性模式
2. **客户购买序列挖掘**
    - 按 customer_id 分组，按时间排序
    - 构建客户购买序列（如：活期存款 → 信用卡 → 消费贷款）
    - 使用序列模式挖掘算法（如 PrefixSpan 或自定义分析）发现常见购买路径
3. **时间窗口关联规则**
    - 定义时间窗口（如 1 个月、3 个月、6 个月）
    - 分析"购买 A 产品后，N 个月内购买 B 产品"的条件概率
    - 发现具有时序依赖的产品推荐规则

提交内容：

- 时间序列分析代码和可视化（各月购买趋势图）
- 客户购买序列挖掘结果（Top 10 常见序列）
- 时间窗口关联规则列表（如"购买信用卡后 3 个月内，45% 客户申请消费贷款"）
- 建议：基于时序规则的产品推荐策略

任务五：结果解读与报告（10 分）

要求：

1. 总结所有挖掘结果
2. 从业务角度解读发现的关联规则
3. 提出基于关联规则的营销策略建议

4. 分析数据挖掘的局限性和改进方向

提交内容：

- 完整的分析报告（Markdown 或 PDF 格式）
- 至少 5 条可落地的业务建议

四、技术要求

5.1 编程语言

- Python 3.8+

5.2 推荐库

```
# 数据处理
import pandas as pd
import numpy as np

# 关联规则挖掘
from mlxtend.frequent_patterns import apriori, association_rules, fpgrowth

# 可视化
import matplotlib.pyplot as plt
import seaborn as sns

# 其他
from collections import defaultdict
from itertools import combinations
```

5.3 代码规范

- 代码需有清晰的注释
- 函数需有文档字符串说明
- 变量命名规范，具有可读性
- 关键步骤需有输出说明

六、提交要求

6.1 提交内容

1. **代码文件**
    - `assignment.py` 或 `assignment.ipynb`（Jupyter Notebook）
    - 包含所有任务的完整代码
2. **分析报告**

    - `report.md` 或 `report.pdf`
    - 包含所有任务的结果、可视化和业务解读
3. **可视化图表**
    - 所有图表需清晰、有标题和坐标轴标签
    - 图表文件保存在 `figures/` 文件夹中

6.2 提交格式

```
提交文件夹结构：
student_name_关联规则作业/
├── assignment.ipynb          # 或 assignment.py
├── report.md                 # 分析报告
├── figures/                  # 可视化图表
│   ├── product_frequency.png
│   ├── age_distribution.png
│   ├── rules_network.png
│   └── ...
└── README.md                 # 说明文档（可选）
```

6.3 提交方式

- 打包为 ZIP 文件
- 命名格式：`学号_姓名_关联规则作业.zip`
- 提交至：[课程平台/邮箱]

七、评分标准

任务	分值	评分要点
任务一：数据探索	15 分	数据理解准确、统计完整、可视化清晰
任务二：基础关联规则	25 分	算法实现正确、规则挖掘有效、对比分析深入
任务三：多维关联规则	25 分	维度分析全面、洞察有深度、业务解读合理
任务四：时序关联规则	25 分	时序分析合理、序列挖掘有效、建议可落地
任务五：报告质量	10 分	报告结构清晰、结论明确、建议有价值
总分	**100 分**	

加分项（额外 10 分）

- 使用网络图可视化关联规则（+3 分）
- 实现自定义关联规则挖掘算法（+4 分）
- 提出创新的分析方法或业务应用（+3 分）

八、参考资料

1. Agrawal, R., & Srikant, R. (1994). Fast algorithms for mining association rules.
2. Han, J., Pei, J., & Yin, Y. (2000). Mining frequent patterns without candidate generation.
3. 《数据挖掘：概念与技术》第 6 章 - 关联分析
4. mlxtend 文档：http://rasbt.github.io/mlxtend/user_guide/frequent_patterns/

九、常见问题

Q1: 支持度和置信度阈值如何设置?
A: 建议先设置较宽松的阈值（支持度 0.05，置信度 0.3），根据挖掘结果调整。如果规则太多，提高阈值；如果规则太少，降低阈值。

Q2: 如何处理 products 字段的逗号分隔格式?
A: 使用 `str.get_dummies(',')` 或自定义函数将逗号分隔的产品列表转换为 One-Hot 编码格式。

Q3: 提升度（Lift）的含义是什么?
A: 提升度 = 置信度 / 期望置信度。提升度>1 表示正相关，=1 表示独立，<1 表示负相关。

Q4: 时序分析中如何处理同一客户的多笔交易?
A: 按 customer_id 分组，按 transaction_date 排序，构建时间序列。可以定义时间窗口来分析先后购买关系。

作业截止日期： [2026-4-19]

提交地址： https://send2me.cn/ic9nPasT/QnG3fZ8NH2KRTg