回归分析及其应用

Statistical Regression Analysis for Financial Products

金融产品关联规则分析与回归建模

内容概览

1. 回归分析基础 - 定义与生活比喻
2. 定性响应变量模型 - Logistic、Probit回归
3. 传统线性回归 - OLS估计与假设检验
4. 正则化方法 - Ridge、Lasso、Elastic Net
5. 降维方法 - PCR与PLS
6. 模型选择与评估 - 交叉验证与指标
7. 金融应用案例 - 信用评分与风险预测

第一部分：回归分析基础

什么是回归分析？

研究"因为A，所以B"关系的统计方法

输入：各种影响因素（收入、年龄、信用记录）

输出：我们关心的结果（会不会违约、收益率多少）

生活中的例子：

- 房价预测：面积、位置、楼层如何影响价格
- 健康风险：年龄、血压、吸烟习惯如何影响心脏病风险
- 金融预测：客户画像如何影响违约概率

回归模型的分类

分类维度	类别	说明
响应变量类型	定量响应变量	连续型结果（收益率、价格）
	定性响应变量	分类型结果（违约与否、评级等级）
响应变量数量	单变量回归	一个响应变量
	多变量回归	多个响应变量
模型形式	线性回归	线性关系假设
	非线性回归	含非线性变换

为什么需要定性响应变量回归？

线性回归的问题：

模型可能预测出"违约概率=120%"或"违约概率=-30%"

概率只能在0-100%之间！

解决方案：

使用特殊的"变形器"，把线性输出变成合理概率值

第二部分：定性响应变量回归模型

二分类Logistic回归

Logistic函数（Sigmoid）是一个"概率压缩器"：

$$P(\text{违约}) = \frac{1}{1 + e^{-z}}$$

- z很大时（100）→ 输出接近1
- z很小时（-100）→ 输出接近0
- z=0时 → 输出正好0.5

发生比（**Odds**）：

- 明天下雨概率80% → 发生比=4:1
- 发生比的Logit变换 → 可用线性模型建模

Logistic回归系数解释

系数就像"影响力评分"

- 收入系数 = -0.5 → 收入越高，违约风险越低
- 负债率系数 = 0.3 → 负债越高，违约风险越高

发生比解释：

- 收入每增加1万元，不违约的发生比增加65%
- 负债率每增加10%，违约的发生比增加35%

多项Logistic回归

适用场景：响应变量有多于两个的无序类别

生活例子：

- 天气：晴天/多云/雨天/雪天
- 交通方式：开车/地铁/公交/骑车

金融应用：

- 投资风格：保守型/平衡型/激进型
- 市场状态：牛市/熊市/震荡市

基准组对比： 以最常见类别为基准，比较其他类别

有序Logistic回归

适用场景：响应变量是有序类别

生活例子：

- 电影评分：1星 < 2星 < 3星 < 4星 < 5星
- 满意度：非常不满意 < 不满意 < 一般 < 满意

金融应用：

- 信用评级：AAA > AA > A > BBB > BB > B > C
- 风险等级：低风险 > 中风险 > 高风险

关键假设： 每个因素对所有评级的影响是相同的

Probit回归

与Logistic的区别：

方面	Logistic	Probit
变换函数	挤压函数	正态分布函数
尾部行为	变化较慢	变化较快
应用偏好	社会科学	金融经济学

为什么金融领域喜欢Probit？

- 理论基础：金融理论假设市场波动服从正态分布
- Merton模型：信用风险模型基于资产价值正态分布假设

第三部分：传统线性回归

线性回归模型形式

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \ldots + \beta_p X_p + \epsilon$$

- Y：预测目标（房价）
- β_0：基础值
- $\beta_1, \beta_2, \ldots$：每个特征的影响力
- $X_1, X_2, \ldots$：特征（面积、楼层、位置）
- ε：误差项

生活比喻： 就像找"最佳裁判"，让所有数据点到裁判的距离最小

OLS估计与推断

最小二乘法原理： 让所有点到直线的距离平方和最小

$$\hat{\beta} = (X^T X)^{-1} X^T Y$$

性质： BLUE（最优线性无偏估计）

系数检验：

- t检验：这个因素真的重要吗？
- p值：p<0.05说明影响显著
- F检验：模型整体是否显著

模型假设与检验

假设	检验方法	不满足会怎样
线性性	残差图、RESET检验	预测不准
误差正态性	Shapiro-Wilk、Q-Q图	推断不准
同方差性	Breusch-Pagan、White检验	权重不等
无自相关	Durbin-Watson	时间序列出问题
无多重共线性	VIF、条件数	系数不稳定

第四部分：正则化方法

为什么需要正则化？

OLS的问题：

1. **过拟合：** 模型记住无关细节（鞋码、早餐）
2. **多重共线性：** 身高体重高度相关，难以区分影响
3. **高维问题：** 100个特征，50个样本

正则化就像"记忆限制"：

- 只记住重要细节，忽略无关细节
- 给模型加上"限制"，防止过拟合

三种正则化方法对比

方法	效果	适用场景
Ridge（L2）	系数缩小但不为0	多重共线性
Lasso（L1）	有些系数变为0（特征选择）	高维稀疏
Elastic Net	结合两者优点	高维+共线性

实际选择：

- 特征数不多，共线性不严重 → Ridge
- 特征数很多，想做特征选择 → Lasso
- 特征数很多，又有共线性 → Elastic Net

第五部分：降维方法

为什么需要降维？

问题场景： 1000个特征预测学生成绩

- 每天早餐吃什么、鞋码多大、父母身高...

降维就像"信息压缩"：

- 原始照片：1000万像素，文件很大
- 压缩后：100万像素，关键信息还在

降维策略：

- 特征选择：从1000个特征选出最重要的10个
- 特征提取：把1000个特征合并成10个综合特征

PCR vs PLS对比

方面	PCR	PLS
降维依据	X的方差	X与Y的协方差
利用Y信息	不利用	利用
预测能力	可能较差	通常更好
过拟合风险	较低	较高

选择建议：

- 预测准确性为主 → PLS
- 模型稳定性为主 → PCR
- 解释性需求 → PCR（主成分正交）

第六部分：模型选择与评估

定量响应变量评估指标

指标	含义	理想值
MSE	均方误差	越小越好
RMSE	均方根误差	越小越好
MAE	平均绝对误差	越小越好
R^2	解释方差比例	越大越好（接近1）
MAPE	平均百分比误差	越小越好（<10%）

定性响应变量评估指标

指标	含义	理想值
准确率	分类正确率	越高越好
精确率	预测为"是"的真确率	越高越好
召回率	实际"是"被找出比例	越高越好
F1	精确率和召回率平衡	越高越好
AUC-ROC	区分能力	越高越好（>0.8）
Log Loss	概率预测质量	越小越好

交叉验证

核心思想： 多次训练和验证，估计模型泛化能力

K折交叉验证：

1. 将数据划分为K个大小相等的子集
2. 每次使用K-1折训练，1折验证
3. 重复K次，计算平均验证误差

常用K值： K=5或K=10

时间序列CV： 金融数据需用时间序列交叉验证，避免未来信息泄露

子集选择方法

方法	原理	适用场景
最佳子集	遍历所有组合	$p < 20$
向前逐步	从空模型逐步添加	$p < 100$
向后逐步	从全模型逐步移除	$p < 100$
正则化	凸优化自动选择	$p > 100$

计算成本： 最佳子集需要拟合2^p个模型

第七部分：金融应用案例

信用评分预测

目标： 预测借款人违约概率

某银行案例发现：

- 收入每增加1万元 → 违约概率下降15%
- 负债率超过60% → 违约概率是普通客户3倍
- 信用记录良好 → 违约概率仅为0.5%

结果： 优化贷款审批策略后，违约率下降30%

资产收益预测

Fama-French三因子模型：

$$R_i - R_f = \alpha + \beta_{MKT}(R_M - R_f) + \beta_{SMB}SMB + \beta_{HML}HML$$

- α：超额能力
- β_MKT：大盘敏感度
- β_SMB：小盘股效应
- β_HML：价值股效应

违约风险预测

Merton结构化模型：

- 企业价值 > 债务 → 股东赚钱
- 企业价值 < 债务 → 可能违约

简化模型：

$$PD = N\left(\frac{\log(D/V) - (\mu - \frac{1}{2}\sigma^2)T}{\sigma\sqrt{T}}\right)$$

某银行发现：

- 负债率超过80% → 违约概率是普通企业5倍
- 现金流为负 → 违约概率增加2倍

模型选择流程

```
开始
 ├── 响应变量类型？
 |   ├── 定量 → 线性回归 → 多重共线性？ → 严重→Ridge/PCR/PLS
 |   |                 轻微→OLS
 |   |                   高维→Lasso/Elastic Net
 |   ├── 定性（二分类）→ Logistic/Probit
 |   ├── 定性（多分类）→ 多项Logistic
 |   └── 定性（有序）→ 有序Logistic
 └── 评估与选择 → 预测为主→CV/AUC   解释为主→AIC/BIC
```

总结：核心要点

1. **Logistic**回归是最常用的分类模型，可输出概率
2. **Ridge/Lasso**解决过拟合和多重共线性问题
3. **降维方法**处理高维特征，PLS考虑目标变量
4. **交叉验证**是评估模型泛化能力的关键
5. **正则化**与**子集选择**是两种特征选择途径

最佳实践建议

- **样本量：** 每个参数至少需要10-20个样本
- **类别不平衡：** 使用class_weight或SMOTE
- **特征标准化：** 正则化方法需要先标准化
- **模型监控：** 定期评估预测性能，监控模型漂移
- **可解释性：** Logistic回归用发生比比解释

参考文献

1. Hosmer, D. W., Lemeshow, S. (2013). *Applied Logistic Regression*. Wiley.
2. Agresti, A. (2010). *Analysis of Ordinal Categorical Data*. Wiley.
3. Hastie, T., Tibshirani, R. (2009). *The Elements of Statistical Learning*. Springer.
4. James, G. et al. (2021). *An Introduction to Statistical Learning*. Springer.
5. Fama, E. F., French, K. R. (1993). *Journal of Financial Economics*, 33(1), 3-56.