回归分析及其应用

金融视角下的统计学习

回归分析：从数据中发现规律，预测未来

目录（1/2）

1. **概述** - 回归分析的定义与分类
2. **多元定性响应变量回归** - Logistic回归与Probit回归
3. **传统多元线性回归** - 模型假设与系数推断

目录（2/2）

4. **回归模型的正则化方法** - 岭回归、Lasso、Elastic Net
5. **回归模型的降维方法** - 主成分回归（PCR）、偏最小二乘（PLS）
6. **回归模型的选择策略** - 评估指标与交叉验证
7. **金融领域应用** - 信用评分、资产收益预测等
8. **代码实战** - 综合案例演示
9. **最佳实践与注意事项** - 模型部署建议

概述：什么是回归分析？

回归分析是研究"因为A，所以B"这种关系的统计方法

生活例子：

- 房价预测：面积、位置、楼层如何影响价格？
- 学生成绩：学习时间、出勤率如何影响考试成绩？
- 健康风险：年龄、体重、血压如何影响心脏病风险？

金融应用：

- 信用评分：预测客户会不会违约
- 资产收益预测：预测股票、基金未来表现

回归模型的分类

分类维度	类别	说明	生活比喻
响应变量类型	定量响应变量	连续型结果（如收益率、价格）	预测"明天会下雨多少毫米？"
	定性响应变量	分类型结果（如违约与否、评级等级）	预测"明天会下雨吗？"（是/否）
响应变量数量	单变量回归	一个响应变量	预测"明天会下雨吗？"
	多变量回归	多个响应变量	同时预测"明天会下雨吗？"和"下多大？"
模型形式	线性回归	线性关系假设	假设房价每平米每增加1平米，价格增加固定金额
	非线性	含非线性变换	假设房价在某个面积区间内增长快，

核心内容三大重点（1/2）

重点一：多元定性响应变量回归

- **二分类问题**：违约/不违约、涨/跌 → Logistic回归、Probit回归
- **多分类问题**：评级AAA/AA/A/BBB → 多项Logistic回归
- **有序分类问题**：风险等级1/2/3/4 → 有序Logistic回归

重点二：回归模型的改进方法

- **正则化方法**：岭回归、Lasso、Elastic Net → 解决过拟合、特征选择
- **降维方法**：主成分回归、偏最小二乘 → 解决多重共线性、高维问题

核心内容三大重点（2/2）

重点三：金融场景预测应用

- **信用评分**：预测客户会不会违约 → 银行决定是否放贷
- **资产收益预测**：预测股票、基金未来表现 → 投资决策
- **市场风险建模**：预测市场波动和风险 → 风险管理

多元定性响应变量回归概览

为什么需要定性响应变量回归？

> 问题：线性回归预测违约概率，可能得出120%或-30%的概率，不合理！

解决方案：需要特殊的"变形器"，把线性模型的输出变成合理的概率值

模型类型	响应变量	适用场景	代表模型	生活比喻
二值响应	0/1（二分类）	违约预测、涨跌判断	Logistic、Probit	明天会不会下雨？（是/否）
多值响应	多类别（无序）	投资风格分类	多项Logistic	你喜欢什么口味的冰淇淋？

二分类Logistic回归

模型原理：Logistic函数（Sigmoid函数）

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

> **生活比喻：** 神奇的"概率压缩器"，把任何数字压缩到0到1之间

发生比（Odds）：

- 明天下雨概率80% → 发生比 = 80%/20% = 4:1
- 对数发生比 = log(4:1) = 1.39

系数解释：

多项Logistic回归与有序Logistic回归

多项Logistic回归（多类别无序）

- **适用场景：** 投资风格分类：保守型/平衡型/激进型
- **生活比喻：** 选择早餐：煮鸡蛋、煎蛋、蒸蛋、炒蛋
- **核心思想：** 以基准类别为参照，比较其他选择

有序Logistic回归（有序等级）

- **适用场景：** 信用评级：AAA > AA > A > BBB
- **生活比喻：** 电影评分：1星 < 2星 < 3星 < 4星 < 5星
- **关键假设：** 每个因素对所有评级的影响是相同的

Probit回归

模型原理：用"正态分布尺子"把分数变成概率

Logistic vs Probit对比：

方面	Logistic	Probit	生活比喻
变换函数	挤压函数	正态分布函数	用橡皮筋 vs 用尺子
系数解释	发生比变化	无直观解释	像"倍数" vs 像"分数"
尾部行为	变化较慢	变化较快	橡皮筋尾端 vs 尺子尾端
计算便利	简单	复杂	用手算 vs 用计算器
应用偏好	社会科学	金融经济学	像心理学 vs 像物理学

选择建议：

传统多元线性回归（1/2）

模型形式：

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \ldots + \beta_p X_p + \epsilon$$

> **生活比喻：** 预测房价 = 固定价格 + 面积×5000 + 楼层×1000 + 位置×2000 + 误差

解释：

- Y：我们想预测的东西（房价）
- β_0：基础值（即使所有特征都是0，也有基础价格）
- $\beta_1, \beta_2, \ldots$：每个特征的影响力

传统多元线性回归（2/2）

经典假设：

假设	生活比喻	检验方法	不满足会怎样
线性性	房价和面积是直线关系	残差图、RESET检验	预测不准（应该用曲线）
误差正态性	预测误差是随机正态分布	Shapiro-Wilk、Q-Q图	统计推断可能不准
同方差性	小房子和大房子的预测误差波动一样大	Breusch-Pagan、White检验	权重不等，预测不准
无自相关	每个房子的预测误差相互独立	Durbin-Watson、Ljung-Box	时间序列数据会出问题
无多重共线性	面积和房间数不能完全相关	VIF、条件数	系数估计不稳定

回归模型的正则化方法

为什么需要正则化？

“ 问题：过拟合、多重共线性、高维问题 ”

正则化就像"记忆限制"：只记住重要细节，忽略无关细节

方法	生活比喻	效果	适用场景
Ridge（L2）	**温和的老师：**让所有学生都发言，但控制发言时间	系数缩小但不为0	多重共线性
Lasso（L1）	**严格的老师：**只让最重要的学生发言，其他学生保持安静	有些系数变为0（特征选择）	高维稀疏
Elastic	**智慧的老师：**既控制发言时间，又	结合两者优点	高维+共

正则化方法详解（1/2）

岭回归（Ridge Regression）：

- 不完全消除任何特征的影响
- 控制所有特征的影响力，防止某个特征过于强大
- 适用场景：特征数不多，共线性不严重

Lasso回归：

- 自动进行**特征选择**
- 不重要的特征系数变为0（完全忽略）
- 适用场景：特征数很多，想做特征选择

正则化方法详解（2/2）

Elastic Net：

- 结合L1和L2惩罚
- 同时享受特征选择和系数稳定性
- 适用场景：特征数很多，又有共线性

参数选择：

- **交叉验证：**用不同严格度管理团队，看哪个效果最好
- **信息准则：**考虑团队表现和管理成本
- **经验法则：**从λ=1开始，逐步调整

回归模型的降维方法

为什么需要降维？

> 问题：特征多，样本少，多重共线性严重

降维就像"信息压缩"：把多个相关特征合并成几个核心特征

方法	生活比喻	原理	适用场景
主成分回归（PCR）	**照片压缩**：把多个特征合并成几个"综合特征"	PCA降维后回归	多重共线性严重
偏最小二乘（PLS）	**智能压缩**：考虑最终目标来压缩	利用Y信息降维	预测为主、高维
Lasso	**特征筛选**：只保留最重要的特征	L1正则化选特征	稀疏解、高维

回归模型的选择策略

模型评估指标：

指标	生活比喻	含义	实际例子
MSE	**平方误差：**把错误平方后平均	均方误差	预测房价差10万，误差就是100（万²）
RMSE	**实际误差：**MSE开根号	均方根误差	预测房价平均差10万
R^2	**解释能力：**模型解释了多少变异	解释方差比例	模型解释了80%的房价变化
AUC-ROC	**区分能力：**区分"是"和"否"的能力	ROC曲线下面积	AUC=0.85表示模型区分能力不错

交叉验证：K折交叉验证（常用K=5或K=10）

金融领域应用（1/2）

信用评分预测：

- **目标：** 预测借款人的违约概率
- **模型：** Logistic回归（能输出概率，有直观解释）
- **关键特征：** 信用评分、负债收入比、信用历史长度

资产收益预测：

- **目标：** 预测资产的未来收益率
- **模型：** 多元线性回归及其改进版本
- **因子模型：** Fama-French三因子模型、Carhart四因子模型

金融领域应用（2/2）

违约风险预测：

- **目标：** 预测企业违约概率（PD）
- **模型：** Logistic回归、有序Logistic、Probit
- **Merton模型：** 基于资产价值正态分布假设

市场反应预测：

- **目标：** 预测事件后的市场反应
- **方法：** 事件研究回归，计算累积异常收益（CAR）

代码实战概述（1/2）

信用评分模型开发流程：

1. 数据准备与探索
   - 数据概览、目标变量分布
   - 违约率统计
2. 特征工程
   - 特征选择、缺失值处理
   - 对数变换、标准化
3. 多重共线性检验
   - VIF（方差膨胀因子）计算

代码实战概述（2/2）

4. 模型开发
   - 基础Logistic回归（统计推断）
   - L1正则化Logistic（特征选择）
   - L2正则化Logistic（系数稳定性）
5. 模型评估与对比
   - AUC、Log Loss计算
   - ROC曲线对比
6. 信用评分转换
   - 违约概率转信用评分

最佳实践与注意事项

定性响应变量回归：

- **样本量要求：**每个参数至少需要10-20个样本（少数类样本）
- **类别不平衡处理：**权重调整、采样技术、阈值调整
- **完全分离问题：**正则化、Firth偏置校正

线性回归改进：

- **异方差处理：**加权最小二乘、稳健标准误
- **时间序列回归：**Newey-West标准误

正则化与降维：

总结

回归分析是金融领域强大的预测工具

三大核心方法：

1. **定性响应变量回归** - 解决分类问题
2. **正则化方法** - 解决过拟合和多重共线性
3. **降维方法** - 解决高维问题

金融应用价值：

- 信用评分：优化贷款审批策略
- 资产收益预测：提高投资决策准确性

谢谢！

问题与讨论

回归分析：从数据中发现规律，预测未来